



UFRN - UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE

IMD - INSTITUTO METRÓPOLE DIGITAL

Modelo Preditivo para Precificação de Imóveis Residenciais

Componente Curricular: IMD3002 Aprendizado de Máquina Supervisionado (T02)

Docente:

Leonardo Enzo Brito da Silva

Discentes:

Eduardo Queiroz C. Gomes,

Esdras Felipe Chaves Pinto N. e Silva e

Marília Yanis Cândido Costa

NATAL, RN

2025

SUMÁRIO

1.	INTRODUÇÃO.....	3
2.	DESCRIÇÃO DA BASE DE DADOS.....	3
3.	METODOLOGIA.....	3
4.	DESENVOLVIMENTO DO PROJETO.....	3
4.1.	COMPREENSÃO DO NEGÓCIO.....	3
4.2.	COMPREENSÃO DOS DADOS.....	5
4.3.	PREPARAÇÃO DOS DADOS.....	5
4.4.	MODELAGEM.....	7
4.5.	AVALIAÇÃO.....	8
5.	CONCLUSÃO.....	9
6.	REFERÊNCIAS.....	11

1. INTRODUÇÃO

A precificação de imóveis constitui uma tarefa intrinsecamente complexa, uma vez que depende de uma vasta gama de variáveis, as quais abrangem desde características físicas estruturais até aspectos subjetivos, como o acabamento. Nesse contexto, a avaliação manual ou baseada apenas na intuição pode acarretar distorções de mercado significativas. Diante desse cenário, o presente projeto propõe o desenvolvimento de um modelo de Aprendizado de Máquina Supervisionado com o objetivo de estimar, de forma objetiva e precisa, o preço de venda de residências. Para tanto, utiliza-se uma abordagem de regressão univariada, visando decodificar o valor real das propriedades a partir de dados históricos.

2. DESCRIÇÃO DA BASE DE DADOS

Para viabilizar o estudo, optou-se pela utilização do Ames Housing Dataset, uma base de dados compilada por Dean De Cock, amplamente reconhecida em competições de ciência de dados, como as do Kaggle. No que tange às suas dimensões, o conjunto de treinamento conta com aproximadamente 1.460 exemplos. Ademais, a base destaca-se pela sua riqueza de detalhes, possuindo 79 variáveis explicativas (features) que descrevem minuciosamente os imóveis, além da variável alvo, o Preço de Venda (SalePrice). Sob esse viés, é válido ressaltar que os dados são heterogêneos, misturando atributos numéricos, ordinais e nominais, o que impõe desafios reais de pré-processamento.

3. METODOLOGIA

A metodologia empregada segue rigorosamente o modelo CRISP-DM, composto pelas etapas de compreensão do negócio, compreensão dos dados, preparação, modelagem e avaliação. Sob esse viés, esse ciclo orienta a construção do modelo desde o entendimento do problema até a interpretação dos resultados, garantindo alinhamento entre requisitos de negócio e coerência estatística.

4. DESENVOLVIMENTO DO PROJETO

4.1. COMPREENSÃO DO NEGÓCIO

O escopo do projeto foi delimitado em torno da tarefa de regressão univariada, tendo como variável alvo o preço de venda (SalePrice) dos imóveis. Para a execução, utilizou-se o conjunto de treino da base de dados Ames Housing, sobre o qual foram aplicados e comparados quatro algoritmos distintos: Regressão Linear (como baseline), Ridge, Lasso e Random Forest. Nesse contexto, os beneficiários diretos dessa solução incluem imobiliárias e corretores, que demandam

estimativas rápidas para cotação, bem como compradores e vendedores interessados em compreender, de forma transparente, quais fatores impactam a valorização imobiliária.

Para a avaliação de desempenho, definiu-se o RMSE (Root Mean Squared Error) como a métrica principal. Sua escolha, calculada no espaço monetário real após a reversão da transformação logarítmica, justifica-se pelo fato de penalizar fortemente grandes erros de predição, os quais são críticos no contexto financeiro de transações imobiliárias. Complementarmente, utiliza-se o R^2 (Coeficiente de Determinação) para mensurar a proporção da variância dos dados explicada pelo modelo. É importante salientar que não foi estipulado um valor absoluto de RMSE como meta; em vez disso, o critério prático de aceitação baseia-se na capacidade do modelo de superar significativamente um baseline simples (como a média dos preços) e demonstrar robustez e estabilidade através da validação cruzada, priorizando a redução consistente do erro e a ausência de viés sistemático nos resíduos.

As decisões técnicas adotadas foram diretamente guiadas pelo entendimento do negócio e pela necessidade de rigor científico. Inicialmente, estabeleceu-se a divisão do dataset na proporção de 80% para treinamento e 20% para teste, fixando-se uma semente aleatória (`random_state=42`) para garantir a reprodutibilidade exata dos experimentos. Concomitantemente, a transformação logarítmica (`log1p`) da variável alvo foi implementada para corrigir a assimetria à direita dos preços, facilitando a otimização das métricas. As estratégias de imputação foram desenhadas para preservar a semântica dos dados: valores nulos (NaN) que representam ausência de característica foram preenchidos como 'None', enquanto variáveis contínuas com dependência local foram imputadas pela mediana. Além disso, aplicou-se o escalonamento via `StandardScaler`, etapa indispensável para assegurar a comparabilidade dos coeficientes nos modelos lineares. A engenharia de atributos também foi priorizada, focando na criação de features de alto impacto econômico, ao passo que se estabeleceu um critério documentado para a remoção de outliers que pudessem distorcer o aprendizado.

Contudo, o desenvolvimento do projeto considerou riscos, pressupostos e restrições inerentes. Uma preocupação central é o data leakage, mitigado ao garantir que operações dependentes de estatísticas globais sejam realizadas estritamente no conjunto de treino (`X_train`), respeitando a divisão 80/20 previamente estabelecida. Adicionalmente, reconhece-se o viés histórico e regional do dataset Ames, o que implica que as previsões podem não generalizar perfeitamente para outros mercados. As limitações computacionais também foram consideradas, restringindo a exaustividade

do GridSearch em modelos complexos. Dessa forma, consideram-se como sinais de sucesso a obtenção de um RMSE inferior ao baseline e a estabilidade do erro entre os folds da validação, enquanto grandes discrepâncias entre o desempenho no treino e no teste serão tratadas como sinais de alerta críticos de overfitting.

4.2. COMPREENSÃO DOS DADOS

Inicialmente, a investigação centrou-se na caracterização estatística da variável dependente (SalePrice), cuja inspeção evidenciou uma distribuição não-Gaussiana marcada por uma assimetria positiva acentuada. Conforme observado nos histogramas preliminares, constatou-se que a maior parte dos imóveis concentra-se em faixas de preço inferiores, enquanto uma "cauda longa" à direita denota a presença de valores extremos que deslocam a média global, sugerindo, desde o princípio, desafios para a aplicação de modelos lineares que pressupõem a normalidade dos resíduos .

Simultaneamente à análise do alvo, o exame detalhado dos tipos de dados (dtypes) revelou inconsistências semânticas que não correspondiam à natureza real das variáveis. Observou-se que atributos como MSSubClass estavam codificados numericamente no conjunto original, apesar de representarem categorias nominais de tipos de habitação, e não grandezas matemáticas contínuas. Ademais, identificou-se a existência de um subgrupo de variáveis qualitativas, tais como a qualidade da cozinha (KitchenQual) e do porão (BsmtQual), que, diferentemente das variáveis puramente nominais, possuem uma hierarquia de valor intrínseca, variando de "Ruim" a "Excelente".

Por fim, a análise bivariada entre a área habitável (GrLivArea) e o preço de venda revelou anomalias significativas no padrão de mercado. Detectaram-se registros pontuais referentes a imóveis com áreas superiores a 4.000 pés quadrados associados a preços desproporcionalmente baixos. Tais observações foram diagnosticadas nesta fase como outliers estruturais ou ruídos de registro que, por destoarem drasticamente da tendência linear da maioria dos dados, apresentavam potencial para distorcer a curva de regressão.

4.3. PREPARAÇÃO DOS DADOS

Durante a Análise Exploratória de Dados (EDA), dois fenômenos estatísticos demandaram atenção prioritária por seu potencial impacto negativo na modelagem. Primeiramente, observou-se uma assimetria positiva acentuada na distribuição da variável alvo (SalePrice), indicando uma cauda longa à direita. Isso significa que, embora a maior concentração de imóveis se encontre em faixas de preço médias, a presença de propriedades de alto valor distorce a média global, o que tende a

enviesar modelos lineares que pressupõem a normalidade dos resíduos. Além disso, a análise bivariada entre a área habitável (GrLivArea) e o preço revelou a existência de outliers estruturais preocupantes: imóveis com área superior a 4.000 pés quadrados sendo comercializados a valores desproporcionalmente baixos. Tais pontos, prováveis resultados de vendas forçadas ou erros de registro, agiriam como alavancas de distorção na regressão, comprometendo a capacidade de generalização do modelo final.




Figura 1 - Histograma da Distribuição Original do Preço de Venda

Fonte: Elaborado pelos autores (2025)

Em resposta a esse diagnóstico, a etapa de preparação foi arquitetada estrategicamente para mitigar os problemas identificados e adequar os dados aos algoritmos de aprendizado. Para assegurar a reprodutibilidade do experimento e evitar o data leakage (vazamento de informações do treino para o teste), todo o fluxo de processamento foi encapsulado em objetos Pipeline e ColumnTransformer da biblioteca Scikit-Learn. O tratamento inicial consistiu na remoção dos imóveis com área superior a 4.000 sqft para higienizar a base de treinamento e, crucialmente, na aplicação de uma transformação logarítmica (np.log1p) sobre a variável SalePrice. Essa operação matemática comprimiu a escala de valores, aproximando a distribuição de uma curva normal, o que estabiliza a variância do erro (homocedasticidade) e potencializa o desempenho de algoritmos lineares como Lasso e Ridge.




Figura 2 - Histograma do Preço de Venda após Transformação Logarítmica

Fonte: Elaborado pelos autores (2025)

Simultaneamente ao tratamento da variável alvo, a diversidade tipológica dos atributos preditores exigiu estratégias distintas de engenharia de atributos. Para as variáveis numéricas, aplicou-se a imputação de valores ausentes pela mediana, métrica mais robusta a outliers que a média, esta seguida pela padronização via `StandardScaler`, colocando todas as features na mesma escala (média 0 e desvio padrão 1). Já os atributos ordinais, que denotam qualidade hierárquica (como `KitchenQual`), foram mapeados explicitamente (`Ex > Gd > TA...`) e processados via `OrdinalEncoder` para preservar a magnitude da informação. Por fim, as variáveis nominais sem ordem intrínseca, como o bairro ou tipo de telhado, foram transformadas em vetores binários através do `OneHotEncoder`, impedindo que o modelo atribuisse falsas relações matemáticas de ordem a categorias puramente qualitativas.

4.4. MODELAGEM

A fase de modelagem não se restringiu ao treinamento padrão, empregando uma validação cruzada (`GridSearchCV` com 5 folds) para explorar o espaço de hipóteses e ajustar os hiperparâmetros de forma robusta. Foram testadas quatro abordagens distintas: a Regressão Linear simples, utilizada como baseline para mensurar o ganho de complexidade; a Ridge Regression (Regularização L2), introduzida para combater a multicolinearidade entre as dezenas de variáveis; a Lasso Regression (Regularização L1), selecionada estrategicamente por sua capacidade de esparsidade e seleção automática de features ao zerar coeficientes irrelevantes; e o Random Forest

Regressor, um modelo de ensemble baseado em árvores de decisão, incluído para capturar interações não-lineares complexas.

```
Iniciando otimização e treinamento...
```

Modelo	Melhores Parâmetros (Resumo)	RMSE (\$)	R ²
Regressão Linear	{}	20,749.65	0.9180
Ridge	{'alpha': 50.0}	19,775.48	0.9255
Lasso	{'alpha': 0.001}	19,211.83	0.9297
Random Forest	{'max_depth': 20, 'min_samples...	25,199.45	0.8790

Figura 3 - Tabela Comparativa de Desempenho dos Modelos

Fonte: Elaborado pelos autores (2025)

4.5. AVALIAÇÃO

A análise comparativa dos modelos, realizada após a reversão da transformação logarítmica para a escala monetária real, revelou insights significativos sobre a natureza do problema. Contra-intuitivamente, o modelo Lasso superou o Random Forest, apresentando o menor erro médio (RMSE) e um coeficiente de determinação, R^2 , superior a 0,90, com um gráfico de dispersão "Real vs. Previsto", ao qual se demonstrou excepcional aderência à linha de identidade. Esse resultado sugere que, após o pré-processamento adequado, a relação entre as características do imóvel e seu preço é predominantemente linear, e que o Lasso foi mais eficaz em filtrar o ruído do dataset do que o Random Forest, que apresentou desempenho inferior nas métricas de erro.




Figura 4 - Gráfico de Barras: Comparação de Erro (RMSE)

Fonte: Elaborado pelos autores (2025)

Apesar de não ter sido o modelo campeão em predição, o Random Forest foi instrumental para a explicabilidade do fenômeno através da análise de importância das variáveis (Feature Importance). A extração das importâncias revelou que a variável OverallQual (Qualidade Geral do Material e Acabamento) é o preditor mais forte, superando até mesmo a GrLivArea (Área Habitável). Economicamente, isso corrobora a tese de que o mercado imobiliário de Ames valoriza a percepção qualitativa e o estado de conservação de forma mais agressiva do que a metragem bruta isolada, sendo seguido por fatores como a área da garagem e a capacidade de carros (GarageCars), que também figuraram no topo da relevância.

5. CONCLUSÃO

A execução deste projeto permitiu validar que a precificação de imóveis, a despeito de sua natureza multifacetada e dependente de fatores subjetivos, pode ser modelada com alta precisão através de abordagens supervisionadas. Um dos insights mais relevantes extraídos do estudo foi a refutação da hipótese inicial de que algoritmos de maior complexidade computacional, como os métodos de Ensemble, seriam intrinsecamente superiores. Ao contrário do esperado, a regularização linear via Lasso demonstrou-se mais robusta que o Random Forest, evidenciando que, em datasets com alta dimensionalidade e ruído, a capacidade de selecionar automaticamente as variáveis relevantes supera a força bruta de modelos não-lineares.

Nesse sentido, a análise crítica do desempenho reforça um paradigma central da Ciência de Dados moderna: a primazia da qualidade dos dados sobre a sofisticação do algoritmo. Conclui-se que o sucesso preditivo alcançado não derivou da escolha de um "modelo mágico", mas sim da coerência metodológica aplicada na etapa de pré-processamento. A linearização do problema e o tratamento hierárquico das categorias provaram ser as verdadeiras alavancas de performance, sugerindo que o esforço investido na engenharia de atributos (Feature Engineering) oferece um retorno sobre o investimento de tempo muito superior ao ajuste fino de hiperparâmetros em modelos complexos.

Ademais, sob a ótica de negócio, o projeto entregou valor para além da predição numérica ao oferecer transparência sobre os vetores de valorização imobiliária. A descoberta de que a Qualidade Geral do Acabamento (OverallQual) exerce influência superior à Área Habitável (GrLivArea) desafia o senso comum de que "tamanho é documento". Para os stakeholders, este achado implica que intervenções qualitativas na propriedade podem ser estrategicamente mais vantajosas do que ampliações físicas. Portanto, o sistema desenvolvido consolida-se não apenas como uma ferramenta de cálculo, mas como um instrumento analítico capaz de desmistificar o mercado e apoiar decisões de investimento com objetividade.

6. REFERÊNCIAS

DE COCK, D. Ames Housing Dataset. Kaggle, 2011. Disponível em: <https://www.kaggle.com/c/house-prices-advanced-regression-techniques>. Acesso em: 1 dez. 2025.

SCIKIT-LEARN DEVELOPERS. Scikit-Learn: Machine Learning in Python. Disponível em: <https://scikit-learn.org/>. Acesso em: 1 dez. 2025.

PROVOST, Foster; FAWCETT, Tom. Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking. Sebastopol: O'Reilly Media, 2013. Disponível em: <https://www.oreilly.com/library/view/data-science-for/9781449374273/>. Acesso em: 3 dez. 2025.